

Détection et classification de manoeuvres GEO par apprentissage supervisé : le dataset SPLID - draft

Etienne Chevrolat

Résumé

On rend compte du travail effectué sur le dataset SPLID (MIT ArcLab) : cinq architectures de modèles de détection de manoeuvres ont été testées. Localisation de manoeuvres et classification des manoeuvres sont deux tâches différentes, la localisation étant le vrai challenge. Le meilleur modèle de localisation de manoeuvres est un CNN à backbone dupliqué par direction (`cnn_split`), doté d'une fenêtre d'entrée asymétrique (128 pas passés, 32 futurs). Il atteint en validation un F_2 de 0,920 en détection de noeuds et 0,896 sur la chaîne complète détection + classification, la classification des noeuds étant quasi parfaite (99,5% sur le type de noeud, 99,0% sur le type de propulsion).

Une analyse par direction montre que le gain provient presque entièrement de l'*allongement du contexte passé*, et non du changement d'architecture : à fenêtre égale, les architectures profondes sont indiscernables entre elles.

Enfin, nous caractérisons quantitativement la raison de l'échec de l'inférence sur les TLE réels de SpaceTrack : SPLID fournit les *éléments osculateurs* de trajectoires *simulées*, échantillonnés régulièrement, là où les TLE sont des *éléments moyens* mesurés à cadence irrégulière, les deux domaines de données sont incompatibles (sans un travail sérieux de mise en correspondance des données, que l'on a pas entrepris)

Toute l'implémentation a été faite dans le repo de travail global `ssa-analysis/`

1 Le dataset SPLID et la tâche

1.1 Structure du dataset

Le dataset SPLID (*Satellite Pattern-of-Life Identification Dataset*) caractérise le Pattern of Life (PoL) de satellites GEO par une suite de noeuds (points de rupture) séparant des *behavioral modes* (modes de comportement constants entre deux noeuds). Nous utilisons le jeu `phase_2`, celui du concours : **1900 objets d'entraînement** et **501 objets de test**, chacun décrit par une série temporelle de 2172 pas de temps à cadence fixe de 2 h (soit environ 6 mois), contenant les éléments orbitaux osculateurs, les positions géographiques et l'état cartésien du satellite.

Labels SPLID

- **Noeuds** : SS (début de période d'étude), ID (*Initiate Drift*), AD (*Adjust Drift*), IK (*Initiate station-Keeping*), ES (fin de période d'étude) ;
- **Types (modes)** : NK (pas de maintien à poste), CK / EK / HK (maintien à poste chimique / électrique / hybride) ;
- **Directions** : chaque noeud est labellisé Est-Ouest (EW, manoeuvres *in plane*) et/ou Nord-Sud (NS, manoeuvres *out of plane*).

Le jeu d'entraînement contient **5360 noeuds de manoeuvre** (2169 IK, 1812 ID, 1379 AD) et 3800 noeuds SS.

1.2 La métrique de performance

Le concours évalue une soumission (liste de noeuds prédits par objet, avec direction, type de noeud et type de propulsion) par appariement aux noeuds vrais avec une **tolérance de ± 6 pas de temps** (12 h), par objet et par direction. Un noeud apparié est un TP si son type de noeud *et* son type de propulsion sont corrects, un FP sinon ; les prédictions non appariées sont des FP et les noeuds vrais manqués des FN. Le score agrégé est le

$$F_2 = \frac{5 TP}{5 TP + 4 FN + FP}$$

qui favorise le rappel (il vaut mieux sur-détecter que manquer une manoeuvre), complété par le RMSE des écarts temporels des TP. Nous avons réimplémenté cet évaluateur à l'identique du `splid-devkit` (`src/ml/splid_eval.py`), avec deux modes :

- **détection seule** : restreint aux noeuds de manoeuvre (ID/AD/IK), l'appariement temporel suffit pour mesurer la qualité du localiser ;
- **chaîne complète** : mode concours, tous les noeuds, un TP exigeant que le type de noeud et le type de propulsion soient corrects.

2 Pipeline de données

Pipeline localizer (détection)

1. **Features continues** : les éléments angulaires discontinus ($e, i, \Omega, \omega, \nu$) sont convertis en éléments équinoxiaux continus ($k, h, q, p, \cos \lambda, \sin \lambda$), ce qui évite les sauts $360^\circ \rightarrow 0^\circ$;
2. **Dérivées discrètes** : on ajoute les incréments $\Delta a, \Delta q, \Delta p$ entre pas consécutifs, qui portent la signature impulsionnelle des manoeuvres, soit 9 features au total ;
3. **Normalisation** : standardisation ajustée sur le train uniquement ;
4. **Cibles** : deux canaux (EW, NS) valant des bosses triangulaires de demi-largeur 6 pas centrées sur les noeuds de manoeuvre, à zéro ailleurs ;
5. **Fenêtrage** : chaque exemple est une fenêtre glissante de 97 pas (48 passés, 48 futurs) centrée sur l'instant à prédire, soit un tenseur (9, 97) ;
6. **Split** : 80/20 *par objet* (1520 objets train, 380 objets validation), pour éviter toute fuite entre train et validation.

Le **classifieur** réutilise les mêmes features et fenêtres, mais échantillonnées uniquement aux instants des noeuds labellisés ; il prédit deux sorties par fenêtre : le type de noeud (ID/AD/IK) et le type de propulsion (NK/CK/EK/HK), avec une pondération de classes compensant le déséquilibre.

3 Modèles

Cinq architectures de localizer ont été réimplémentées et comparées, à features identiques :

- **naive_baseline** : une simple couche linéaire sur la fenêtre aplatie (calibre le problème) ;
- **small_cnn** : 3 couches de convolution 1D (64, 64, 48 canaux, noyaux 7) + tête dense ;
- **small_lstm** : une couche LSTM (32 unités) + max-pooling temporel + tête dense ;
- **cnn_lstm1** : **CNN et LSTM en série** : les 3 couches de convolution extraient les motifs locaux et compressent l'axe temporel ($97 \rightarrow 40$), puis un LSTM (64 unités) agrège séquentiellement, suivi d'un max-pooling et d'une tête dense à 2 sorties (probabilité d'un noeud EW / NS au centre de la fenêtre) ;
- **cnn_split** : **CNN pur à backbone dupliqué par direction**


L'architecture retenue : **cnn_split** avec une pile plus profonde : 5 blocs au lieu de 3. Chaque bloc suit la structure suivante, Conv1d $\rightarrow$ ReLU $\rightarrow$ BatchNorm $\rightarrow$ Dropout, la normalisation intervenant *après* l'activation. Les deux branches sont ensuite concaténées vers une tête dense partagée (64, 32), chaque direction conservant sa propre sortie.

Les entraînements ont été menés sur les GPUs (NVIDIA RTX 4000 Ada) de l'X.

4 Résultats

4.1 Comparaison des architectures

Courbes de validation des localizers (loss BCE et F_2 à seuil de détection fixe de 0,1) :




Modèle	Fenêtre	F_2 max en validation (seuil 0,1)
naive_baseline	48/48	0,372
small_lstm	48/48	0,713
small_cnn	48/48	0,727
cnn_lstm1 (série)	48/48	0,734
cnn_split	48/48	0,741 <i>et</i> 0,737
cnn_split	128/32	0,764

La baseline linéaire décroche nettement, ce qui confirme que la tâche exige bien une modélisation de la structure temporelle. Les architectures profondes, en revanche, se tiennent dans un mouchoir de poche à fenêtre égale (0,713 à 0,741).

4.2 L'écart entre directions

Le score global masque une asymétrie forte entre les deux directions. Nous mesurons donc chaque architecture direction par direction, chacune à son propre seuil optimal, afin que la comparaison ne dépende pas d'un seuil global favorisant la direction dominante :



Modèle	Fenêtre	F_2 EW (in-plane)	F_2 NS (out-of-plane)
naive_baseline	48/48	0,450	0,302
small_lstm	48/48	0,916	0,742
small_cnn	48/48	0,940	0,776
cnn_lstm1	48/48	0,958	0,808
cnn_split	48/48	0,963	0,810
cnn_split	128/32	0,962	0,849

Trois enseignements se dégagent :


La détection NS est systématiquement plus mauvaise Quelle que soit l'architecture, le F_2 NS accuse 0,12 à 0,17 de retard sur le F_2 EW. Le déficit porte sur le *rappel* (les manoeuvres out-of-plane sont manquées, non sur-détectées), et non sur la précision.

Le backbone dupliqué ne corrige pas cet écart. À fenêtre égale, `cnn_split` obtient 0,810 en NS contre 0,808 pour `cnn_lstm1` : la séparation des deux branches, qui devait précisément éviter qu'un backbone commun sacrifie la direction minoritaire, ne change rien de mesurable. L'hypothèse d'un compromis imposé par le partage de paramètres n'est donc pas ce qui limitait la détection NS.

C'est le contexte passé qui compte. Tout le gain NS provient de l'allongement de la fenêtre (0,810 $\rightarrow$ 0,849, rappel 0,799 $\rightarrow$ 0,853), à architecture inchangée.

4.3 Choix du seuil de détection

La sortie du localizer est une probabilité par pas de temps ; les noeuds prédits sont les centres des plages au-dessus d'un seuil. Ce seuil arbitre précision contre rappel. Les comptages TP/FP/FN s'additionnant entre directions, nous les tabulons une fois par direction et par seuil, puis cherchons le couple (seuil EW, seuil NS) optimal sur la grille :



Le seuil optimal est très différent d'une direction à l'autre : 0,76 en EW contre 0,16 en NS. Cet écart est une mesure directe de l'asymétrie décrite plus haut.

Relever le seuil au-delà du défaut de 0,1 apporte en revanche un gain net (F_2 passant de 0,764 à 0,916) : le modèle produit des pics francs, et remonter le seuil élimine beaucoup de fausses alarmes de faible amplitude sans coûter de rappel.

C'est une différence de fond avec les méthodes par seuillage de résidus (filtre de Kalman, cf. rapport précédent) : le seuil s'applique ici à une probabilité apprise, homogène d'un satellite à l'autre, et non à une grandeur physique dont l'échelle varie selon l'objet. Il se règle donc (si tout va bien) *une seule fois* pour tout le catalogue, ce qui lève l'obstacle principal à l'automatisation identifié précédemment.

4.4 Score officiel en validation

Évaluateur officiel du concours sur les 380 objets de validation :

	Précision	Rappel	F_2	RMSE (pas)
Détection seule (ID/AD/IK)	0,945	0,914	0,920	0,54
Chaîne complète (mode concours)	0,761	0,938	0,896	0,41


En détection seule : 972 TP pour seulement 57 FP et 91 FN. Le RMSE de 0,54 pas signifie que les noeuds détectés sont localisés à moins de 1,1 h de la manoeuvre vraie en moyenne — une précision temporelle très supérieure à la tolérance de 12 h.



4.5 Exemples



On présente dix objets de validation comportant au moins trois noeuds de manoeuvre.

Pour chacun : demi-grand axe, inclinaison, et sortie du localizer, superposés aux labels (traits verticaux, EW en bleu plein, NS en orange pointillé).


Les labels SPLID ne marquent pas toutes les manoeuvres, mais uniquement les manoeuvres de changements de *pattern of life*.











Objet 573 (validation) : labels (traits verticaux) vs sortie du localizer — TP 3 / FP 0 / FN 0



Objet 796 (validation) : labels (traits verticaux) vs sortie du localizer — TP 5 / FP 0 / FN 0








4.6 Classification des noeuds

Le classifieur `cnn_lstm1` sur les noeuds de validation :


Classifier `cnn_lstm1` : matrices de confusion (validation)



La classification est quasi parfaite en validation : 99,5% d'exactitude sur le type de noeud (5 erreurs sur 1063) et 99,0% sur le type de propulsion. Les signatures des différents régimes (CK : impulsions fortes et espacées; EK/HK : poussées faibles quasi continues) sont donc parfaitement séparables par le réseau — *lorsque la distribution d'entraînement couvre celle d'évaluation*, ce qui n'est plus le cas sur le jeu de test (section précédente).

5 Le problème du transfert vers SpaceTrack

L’objectif final reste la détection sur données réelles. Une passe d’inférence des modèles entraînés sur SPLID a donc été menée sur notre historique de TLE SpaceTrack de satellites GEO, remis au format SPLID (renommage des colonnes, ré-interpolation des éléments équinoxiaux sur une grille régulière de 2 h, découpage aux trous de données). **Les résultats sont inexploitable**, et l’analyse quantitative des deux domaines montre que ce n’est pas un problème d’architecture ni d’entraînement, mais d’incompatibilité de la nature même des données.



Éléments osculateurs contre éléments moyens. C’est le point central. La documentation du dataset l’indique explicitement : SPLID fournit les *éléments orbitaux osculateurs* de trajectoires produites par un simulateur haute fidélité. Le demi-grand axe y porte donc les oscillations à courte période (12 h et 24 h en GEO, dues aux harmoniques du champ terrestre), d’amplitude crête-à-crête de plusieurs kilomètres — parfaitement visibles sur le panneau de gauche. Les TLE de SpaceTrack sont au contraire des *éléments moyens* au sens SGP4 : ces termes à courte période en ont été analytiquement retirés, et la série est lisse. Quantitativement, l’écart-type des incréments Δa entre échantillons successifs, qui est l’une des features principales du modèle, vaut en médiane :

$$\sigma(\Delta a)_{\text{SPLID}} = 5,36 \text{ km} \quad \text{contre} \quad \sigma(\Delta a)_{\text{SpaceTrack}} = 0,028 \text{ km},$$

soit un rapport de près de **200**. La composante dominante de la variance des features apprises n’existe tout simplement pas dans les TLE.

Cadence d’échantillonnage. SPLID est échantillonné exactement toutes les 2 h. Les TLE arrivent à intervalles irréguliers, de médiane 5,7 h pour le satellite GEO représenté, avec une queue au-delà de 20 h. La ré-interpolation sur une grille de 2 h fabrique donc de longues plages artificiellement lisses entre deux TLE, sans équivalent dans les données d’entraînement.

Données simulées contre données mesurées. Enfin, les trajectoires SPLID d’entraînement sont simulées, donc exemptes du bruit d’estimation propre aux TLE, qui résultent d’un ajustement sur observations radar et optiques.

Le modèle apprend donc des signatures fines dans des séries propres, régulières et riches en oscillations à courte période — signatures qui n’existent pas sous cette forme dans les TLE réels. C’est un *domain gap* au sens strict.

6 A suivre

- La pipeline SPLID est complète, reproductible et évaluée avec la métrique officielle du concours, sur le jeu d’entraînement comme sur le jeu de test : elle constitue un banc d’essai fiable pour itérer sur les architectures ;
- les performances en validation ($F_2 = 0,920$ en détection, classification des noeuds à 99%) montrent que l’approche par fenêtre glissante apprend effectivement les signatures de manoeuvres, et que le seuil de détection y est réglable une fois pour toutes — deux propriétés que les méthodes par filtrage de Kalman n’offraient pas ;
- l’écart à notre score de test (0,675 contre 0,805 pour le gagnant) est à combler en priorité, par deux voies identifiées : une tête de classification dédiée aux noeuds SS (aujourd’hui prédits sur une fenêtre à moitié vide, et responsables de la majorité des faux positifs), et un rééquilibrage ou une augmentation des données ciblant les régimes de propulsion électrique et hybride, sous-représentés à l’entraînement ;
- la piste la plus prometteuse pour la détection out-of-plane est l’**extension du contexte temporel**, seul levier ayant produit un gain net (F_2 NS de 0,810 à 0,849) là où le changement d’architecture n’a rien donné. Les fenêtres au-delà de 128 pas, ou des convolutions dilatées à champ réceptif encore plus large, restent à explorer ;
- pour les données réelles, le transfert direct depuis SPLID est une impasse. Deux pistes : dégrader les données SPLID pour les rapprocher du domaine TLE (passage aux éléments moyens par filtrage des termes à courte période, sous-échantillonnage irrégulier, ajout de bruit d’estimation), et/ou entraîner directement sur des TLE réels labellisés (labels ILRS en LEO, labellisation manuelle en GEO, cf. rapport précédent) ;
- le pré-entraînement non supervisé (MAE) sur l’historique massif SpaceTrack, en cours, vise le même objectif : apprendre des représentations directement dans le domaine des TLE réels.